

Generalized Additive Models per la Previsione dei Prezzi delle Case a Milano

Tommaso Menghini matricola 864946

1 Pre-Processing e Imputazione Dati Mancanti

Il training set comprende 8000 osservazioni, corrispondente ciascuna ad una casa localizzata nella circoscrizione comunale di Milano. Per ogni record si hanno a disposizione 16 covariate che descrivono caratteristiche dell’abitazione e la variabile risposta, il prezzo di mercato della casa. La covariata `other.features` è una stringa con al suo interno una miscellanea di informazioni aggiuntive. Da quest’ultima allora si possono creare una serie di altre covariate che sono descritte in appendice A nella tabella 4. In totale nel dataset si hanno 5678 valori mancanti e questo rappresenta un problema. Per decidere come gestirli è necessario capire il meccanismo che sta alla base dei dati mancanti. Un possibile approccio è quello di semplificare il problema scartando tutte le osservazioni con valori mancanti. Questa soluzione però è pericolosa per due ragioni principalmente: 1. se le osservazioni con valori mancanti differiscono in modo sistematico dalle osservazioni complete l’analisi potrebbe essere distorta; 2. se nel modello si considerano tante variabili, allora le osservazioni con i valori completi potrebbero essere poche e quindi una sostanziale parte del dataset potrebbe andare persa insieme all’informazione che porta con sé. Nel caso in questione le righe con almeno un missing value sono 3790, un numero considerevole, ed una eventuale rimozione di tutta questa informazione comprometterebbe l’analisi. Piuttosto che eliminare osservazioni, un approccio alternativo è rappresentato dall’imputazione dei valori mancanti. La variabile `zona` indica il quartiere in cui si trova l’abitazione. È una variabile categorica che assume più livelli. Alcuni di questi sono poco frequenti, pertanto sono stati accorpati ad altri geograficamente vicini. Il raggruppamento è stato effettuato in maniera manuale, senza un criterio formale (i.g. coordinate geografiche); l’obiettivo era mantenere una coerenza geografica plausibile. Una prima idea era stata quella di raggruppare tutte quelle zone che avessero una frequenza minore del primo quartile, ma così facendo sarebbe significato ricodificare la zona di 442 osservazioni, troppe. Si è quindi optato di ricodificare invece quei livelli con una frequenza minore di 10. Inoltre per la variabile `zona` si ha un dato mancante, che viene imputato con la moda. La variabile `square.meters` indica i metri quadri dell’abitazione. Non ha dati mancanti, ma sono presenti delle inconsistenze. Infatti la covariata assume, per certe osservazioni, valori al di sotto del limite legale dell’estensione di una casa. La superficie minima di un monolocale destinato ad una persona, secondo la normativa vigente (Decreto Ministeriale 5 luglio 1975), è di 28 mq. Nel 2024 è scesa a 20 mq. Pertanto tutti quei valori minori di quest’ultimo sono stati resi NA. La variabile `year` indica l’anno di costruzione della casa. Si tratta di una variabile continua, ma è stata discretizzata. Infatti, sebbene discretizzare una variabile continua non sia spesso una grande idea, farlo con l’età può avere senso per identificare dei pattern generazionali. Le variabili `total.floors` e `floor` sono estremamente collegate. La prima indica il numero di piani dell’edificio in cui si trova l’appartamento, mentre la seconda indica il piano esatto in cui l’abitazione si trova. È facile notare dalla tabella di contingenza che ci sono delle inconsistenze: infatti per 31 osservazioni è stato registrato un valore di `total.floors` minore di `floor`. Questo rappresenta chiaramente un errore di inserimento del dato. È ragionevole pensare che il piano a cui si trova sia un’informazione cruciale per un’abitazione, quindi è più plausibile che il valore errato sia quello legato alla variabile `total.floors`. Pertanto i valori corrispondenti a queste osservazioni per questa covariata sono stati posti come NA. La variabile `lift` indica la presenza o assenza di un ascensore nell’edificio in cui si trova l’appartamento. Anche in questo caso si hanno degli NA. La Legge 13/1989 e il Decreto Ministeriale 236/1989 regolano

l'obbligo di installare un ascensore in un edificio residenziale con più di tre piani fuori terra, pertanto tutti i valori mancanti in corrispondenza di osservazioni con valore della variabile `total.floors` maggiore di 3 sono stati posti pari a "yes". Per il resto dei *missing values* si è optato per imputare con la moda condizionata alla covariata `total.floors`. La variabile `conditions` indica lo stato della casa. Anche in questo caso si hanno degli NA; essendo un predittore categorico non ordinato, un approccio semplice per l'imputazione è quello di aggiungere una categoria extra che indica che il valore della variabile è mancante. Viene creata una nuova variabile `house.efficiency` che indica il livello di efficienza energetica della casa. Le categorie sono tre: "Low", "Medium" e "High", e derivano da un raggruppamento della vecchia covariata `energy.efficiency.class`. La variabile `condominium.fees` contiene informazioni sulle tasse condominiali legate all'abitazione. Chiaramente non tutte le case appartengono ad un condominio, quindi questa è una variabile continua che può assumere valore 0 o un valore positivo maggiore di 0. Ci sono inoltre 23 osservazioni per cui il valore della covariata è maggiore di 2500. Ipotizzando che in questo caso ci si riferisca alle spese condominiali mensili, è piuttosto improbabile che vi possano essere valori più elevati di quest'ultimo. Allora si è deciso di rendere NA questi 23 valori. Nella tabella 1 vengono mostrate le variabili con NA ed il loro numero.

Tabella 1: Valori mancanti per variabile

Variabile	Numero di NA	Perc. di NA sul totale
<code>square.meters</code>	16	0.2%
<code>bathrooms.number</code>	25	0.3%
<code>heating.centralized</code>	63	0.8%
<code>total.floors</code>	102	1.3%
<code>year</code>	789	9.9%
<code>house.efficiency</code>	842	10.5%
<code>condominium.fees</code>	907	11.3%

In Gelman and Hill (2006) si spiega che l'approccio diretto all'imputazione di valori mancanti in più predittori è quello di costruire un modello multivariato che comprende tutte le variabili che hanno dei *missing values*. Questo approccio però presenta delle difficoltà pratiche perché non è semplice pensare ad un modello di regressione multivariato ragionevole. Esistono approcci automatici a cui si può fare appello, ma come detto sempre in Gelman and Hill (2006) usarli sarebbe in una certa misura "premere bottoni". Si è quindi deciso di percorrere un'altra strada, quella della *iterative regression imputation*. Se le variabili con i missing sono le colonne $\tilde{y}_1, \dots, \tilde{y}_k$ di una matrice Y e i predittori completamente osservati sono una matrice X , allora si potrebbe inizialmente imputare tutti i valori mancanti di Y con un metodo grezzo e poi imputare ad una a una le colonne di Y : $\tilde{y}_1$ dati $\tilde{y}_2, \dots, \tilde{y}_k$ e X ; $\tilde{y}_2$ dati $\tilde{y}_1, \dots, \tilde{y}_k$ e X , usando i valori appena imputati per $\tilde{y}_1$; e così via fino ad arrivare ad una convergenza approssimata. Chiaramente lavorare con l'insieme dei modelli univariati è più semplice che costruire un unico modello di regressione multivariato e questo è un grande vantaggio dell'*iterative regression imputation*. Dall'altra parte però è necessaria cautela nel creare i modelli di regressione separati ed evitare inconsistenze. Inoltre è anche cruciale controllare la ragionevolezza delle imputazioni, ad esempio con istogrammi dei valori osservati ed imputati. In questo caso si è deciso di inizializzare i valori mancanti imputando un valore a caso tra quelli osservati per ciascuna variabile (*random imputation*). Nella tabella 2 si mostrano i modelli univariati utilizzati per ogni variabile coinvolta nel processo d'imputazione dei valori mancanti.

Le covariate `bathrooms.number`, `house.efficiency` e `year` sono variabili categoriche ordinali. Si è usato il modello logistico cumulato per risposte ordinali, approfondito in Agresti (2013) proprio per sfruttare questo aspetto. Per la variabile `condominium.fees` si costruisce un modello a due stadi. Prima si imputa un indicatore che indica se la variabile è positiva oppure uguale a zero, e solo in seguito si imputa un valore continuo positivo. Nella pratica il primo modello, quello per l'indicatore, è una regressione logistica, mentre il secondo è un modello lineare (costruito sulla radice quadrata dei valori positivi di `condominium.fees` per garantire che le previsioni siano positive). Come precedentemente citato questo metodo d'imputazione prevede di iterare le imputazioni fino ad arrivare a convergenza. Si è deciso di iterare il processo per sette volte, una scelta arbitraria, e controllando il MAE e l'Accuracy dei modelli nel ciclo si può notare che nel momento in cui questi non cambiano si è arrivati a convergenza. L'ultimo passo dell'imputazione è controllare la ragionevolezza dei valori imputati. In figura 1 e 2

Tabella 2: Modelli di imputazione per ciascuna variabile

Variabile da imputare	Modello	Variabili utilizzate
square.meters	Modello Lineare	bathrooms.number, rooms.number
bathrooms.number	Modello Logistico Cumulato per Risposte Ordinali	rooms.number, square.meters
heating.centralized	Modello Logistico	conditions, condominium.fees, house.efficiency, fireplace
house.efficiency	Modello Logistico Cumulato per Risposte Ordinali	conditions, heating.centralized, condominium.fees, year, pool, fireplace, hydromassage
year	Modello Logistico Cumulato per Risposte Ordinali	conditions, house.efficiency, zona, fireplace, optic.fiber
condominium.fees	Modello a due Stadi	lift, heating.centralized, total.floors, car.parking, reception, pool, hydromassage, conditions, house.efficiency
total.floors	Modello Lineare	condominium.fees, floor

sono mostrati rispettivamente gli istogrammi dei valori osservati e dei valori imputati delle variabili `condominium.fees` e `total.floors`. Si può notare come le imputazioni siano ragionevoli. Tutti i passaggi di pulizia del dato e di imputazione sono stati replicati esattamente sul test set, che comprende 4800 osservazioni.




Figura 1: Istogramma dei valori osservati di `condominium.fees` e dei valori imputati




Figura 2: Istogramma dei valori osservati di `total.floors` e dei valori imputati

2 Modellistica e Risultati


Si divide il training set totale in training (5280 oss.) e validation set (2720 oss.). Il primo modello che si prova è un semplice modello lineare. Quest'ultimo però non impone nessun vincolo che forza le previsioni del modello ad essere positive, e prevedere delle osservazioni con **selling price** negativa non avrebbe alcun senso. In contesti del genere, in cui la variabile risposta ha valori strettamente positivi è comune applicare una trasformazione logaritmica; in seguito le previsioni del modello saranno trasformate in scala originale applicando l'esponenziale e questo garantisce la positività dei valori previsti dal modello. Si inizia quindi l'analisi con il primo modello che ha la seguente forma:

$$\log(\text{selling.price}_i) = \beta_0 + \beta_1 \text{square.meters}_i + \beta_2 \text{zona}_i + \beta_3 \text{condominium.fees}_i + \beta_4 \text{conditions}_i.$$

Sono state scelte queste covariate senza un criterio formale, ma seguendo il senso comune. Ogni modello è un'approssimazione della realtà, ma in questo caso emergono dei problemi non ignorabili. Dai grafici 3 si può notare come la relazione tra il logaritmo della variabile risposta e `square.meters` e `condominium.fees` sia non lineare. Un approccio non parametrico per modellare queste covariate potrebbe essere una valida alternativa.

Si è quindi deciso di utilizzare un GAM perché permette l'inclusione nel modello sia di funzioni *smooth* che di termini lineari. Nel caso in questione si è deciso di modellare in modo non parametrico le covariate `square.meters`, `condominium.fees` e `total.floors`, attraverso le low rank thin plate regression splines, non approfondite in questo progetto, ma spiegate in Wood (2003). Per la scelta dei

Figura 3: Scatterplot con stima Loess



tre smoothing parameters si è utilizzato il REML, un criterio alternativo al GCV che dal punto di vista operativo è una sua variante asintotica. Per quanto riguarda i predittori rimanenti, tutti entrano come termini lineari nel modello. In conclusione la specificazione del modello è la seguente:

$$\log(\text{selling.price}_i) = \beta_0 + f_1(\text{square.meters}_i) + f_2(\text{condominium.fees}_i) + f_3(\text{total.floors}_i) + \sum_{j=1}^{p-3} \beta_j \tilde{x}_j;$$

con $\tilde{x}_j$ che rappresenta le covariate che entrano in maniera lineare nel modello.

term	edf
s(square.meters)	8.107
s(condominium.fees)	3.592
s(total.floors)	3.882

Tabella 3: Effective Degrees of Freedom delle funzioni smooth




Figura 4: Effetto Parziale della variabile (a) `square.meters`, (b) `condominium.fees`, (c) `total.floors`

In tabella 3 vengono mostrati gli *effective degrees of freedom* delle spline utilizzate. Sono tutti diversi da 1, qualora fosse stato il contrario avrebbe voluto dire che $\hat{f}_j$ sarebbe collapsata ad un termine lineare. Un vantaggio dei GAM è che come i modelli lineari sono interpretabili, la variazione della risposta, variando un predittore singolo, tenendo gli altri fissi, non dipende dal valore degli altri predittori. Questo comporta che si può analizzare il grafico delle funzioni $\hat{f}_j$, come in figura 4 per esaminare il ruolo di questi predittori nel modellare la risposta. Ad esempio per la variabile `square.meters` come ci si poteva aspettare si vede che il prezzo di una casa aumenta con l'aumentare dei metri quadri dell'abitazione, ma che questo effetto tende a diminuire ed essere più incerto (per la *wiggleness* sull'estremo destro della funzione) per case sempre più estese. Invece sia per `condominium.fees` che `total.floors` non sembra esserci forte effetto sulla variazione della variabile risposta. In conclusione il MAE valutato sul validation set è pari a 78937.59. Ulteriori sviluppi utili per arricchire e completare lo studio in questione possono essere l'adozione di metodi di variable selection o di shrinkage.

Riferimenti bibliografici

Alan Agresti. *Categorical Data Analysis*. John Wiley & Sons, Inc., Hoboken, NJ, USA, 3rd edition, 2013. ISBN 978-0-470-46363-5.

Andrew Gelman and Jennifer Hill. *Data Analysis Using Regression and Multilevel/Hierarchical Models*. Analytical Methods for Social Research. Cambridge University Press, 2006.

Simon N. Wood. Thin plate regression splines. *Journal of the Royal Statistical Society. Series B (Statistical Methodology)*, 65(1):95–114, 2003.

A Appendice A

Variabile	Descrizione
<i>fireplace</i>	Assume valore 1 se è presente un camino nell'abitazione, 0 altrimenti.
<i>hydromassage</i>	Assume valore 1 se è presente l'idromassaggio nell'abitazione, 0 altrimenti.
<i>video entryphone</i>	Assume valore 1 se è presente il citofono video, 0 altrimenti.
<i>terrace</i>	Assume valore 1 se è presente una terrazza nell'abitazione, 0 altrimenti.
<i>security door</i>	Assume valore 1 se la porta dell'abitazione è blindata, 0 altrimenti.
<i>tavern</i>	Assume valore 1 se è presente una taverna nell'abitazione, 0 altrimenti.
<i>optic fiber</i>	Assume valore 1 se è presente la fibra ottica nell'abitazione, 0 altrimenti.
<i>electric gate</i>	Assume valore 1 se è presente un cancello elettrico nell'abitazione, 0 altrimenti.
<i>pool</i>	Assume valore 1 se l'abitazione ha una piscina, 0 altrimenti.
<i>tennis court</i>	Assume valore 1 se l'abitazione ha un campo da tennis, 0 altrimenti.
<i>alarm system</i>	Assume valore 1 se l'abitazione è dotata di un sistema d'allarme, 0 altrimenti.
<i>attic</i>	Assume valore 1 se l'abitazione è un attico, 0 altrimenti.
<i>balcony</i>	Assume valore 1 se l'abitazione è dotata di un balcone, 0 altrimenti.
<i>cellar</i>	Assume valore 1 se nell'abitazione è presente uno scantinato, 0 altrimenti.
<i>closet</i>	Assume valore 1 se nell'abitazione è presente una cabina armadio, 0 altrimenti.
<i>reception</i>	Assume valore 1 se il condominio dell'appartamento è dotato di portineria, 0 altrimenti.
<i>concierge</i>	Descrive la presenza di un tuttodore nel condominio, assume valore 1 se è disponibile tutto il giorno, 0.5 se è disponibile per mezza giornata, 0 altrimenti.
<i>furniture</i>	Descrive il livello di arredamento della casa, assume valore 1 se la casa è completamente arredata, 0.5 se lo è solo parzialmente, 0 altrimenti.
<i>garden</i>	Assume valore <i>private</i> se il giardino della casa è d'uso privato, <i>shared</i> se è condiviso con altri appartamenti, altrimenti <i>no_garden</i> .
<i>exposure</i>	Indica la tipologia di esposizione della casa, assume valore <i>double</i> se la casa ha doppia esposizione, <i>single</i> se ha esposizione singola, e <i>other</i> se non è specificato nulla.
<i>window frames</i>	Indica la tipologia di vetro di una finestra, assume valore <i>triple</i> se è triplo, <i>other</i> se è di un altro tipo.
<i>window material</i>	Indica il materiale degli infissi, assume valore <i>wood</i> se gli infissi sono di legno, <i>other</i> altrimenti.

Tabella 4: Elenco delle variabili ottenute da *other features* e loro descrizione